


# Presentations, structured.

Upload a slide deck. Get clean JSON and a downloadable Excel sheet — extracted by a vision-language pipeline.



| result.json                                                                                                                                                                                                                                                        | result.xlsx |             |          |            |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------|-------------|----------|------------|
| <pre>{   "metadata": {     "filename": "deck.pptx",     "slide_count": 12,     "pipeline_version": "0.1.0"   },   "slides": [     {       "index": 1,       "title": "Q3 Review",       "hasTable": true     },     { "index": 2, "title": "Revenue" }   ] }</pre> | key1        | key2        | key3     | value      |
|                                                                                                                                                                                                                                                                    | metadata    | filename    |          | deck.pptx  |
|                                                                                                                                                                                                                                                                    | metadata    | slide_count |          | 12         |
|                                                                                                                                                                                                                                                                    | slides      | 0           | title    | Q3 Review  |
|                                                                                                                                                                                                                                                                    | slides      | 0           | hasTable | true       |
|                                                                                                                                                                                                                                                                    | slides      | 1           | title    | Revenue    |
|                                                                                                                                                                                                                                                                    | slides      | 1           | metric   | +18%       |
|                                                                                                                                                                                                                                                                    | slides      | 1           | region   | APAC, EMEA |
|                                                                                                                                                                                                                                                                    | slides      | 2           | title    | Pipeline   |

## WHY

### 슬라이드 안에 잠긴 데이터를 풀어내기.

분기 보고서·연구 정리·운영 지표 — 회사의 핵심 데이터는 PowerPoint 안에 살지만, 표·키·값을 다시 기계가 읽을 수 있게 꺼내는 건 매번 수작업이었다. ppt2json 은 한글 슬라이드와 중첩 표까지 자동 추출하는 비전-언어 파이프라인으로 그 단계를 통째로 없앤다.

## PIPELINE

### .pptx 에서 JSON 까지, 다섯 단계.

- 1 전처리 · 표 마스킹**  
 LibreOffice·poppler 로 슬라이드를 렌더하고, 복잡한 표는 별도 sub-slide 로 분리.
- 2 Key-Value 추출**  
 비전-언어 모델이 슬라이드 이미지를 읽고 초기 JSON 을 만든 뒤 refine.
- 3 중첩 표 분석**  
 VQA 단계가 마스킹된 복잡한 표의 행·열 구조를 복원.
- 4 병합 · 후처리**  
 본문과 표 JSON 을 하나의 구조화된 문서로 합치고 정제.
- 5 JSON · Excel 내보내기**  
 결과를 JSON 으로 제공하고, 동일 데이터를 .xlsx 로 다운로드.

# 슬라이드에서 데이터까지, 다섯 단계.


한글 슬라이드와 중첩 표까지 추출하는 비전-언어 파이프라인이 PPT 를 JSON 과 Excel 로 변환합니다.

01

## 전처리 · 렌더링

슬라이드를 이미지로 굽고, 복잡한 표는 분리해서 따로 다룬다.

- `python-pptx` 로 슬라이드 파싱 → 셀 병합·중첩 셀 휴리스틱으로 복잡 표 감지
- 감지된 표는 "표 자리 N" placeholder 로 마스킹 + 별도 sub-pptx 로 저장
- LibreOffice headless ( `UserInstallation` 격리) 로 .pptx → PDF 변환
- `pdf2image` 가 PDF → 슬라이드 PNG 300 DPI, shape 별 entity JSON 직렬화



02

## Key-Value 추출

비전-언어 모델이 슬라이드를 읽고 초기 JSON 을 만든 뒤 reflect 한다.

- 슬라이드 이미지 + 추출 텍스트를 `gpt-5.4` Vision 입력으로 동시 전달
- 초기 응답 → 동일 모델로 `max_refine_iters` 회 self-refine 루프
- 슬라이드별 `{slide}.json` + 통합 `kv_results.json` 저장

```
result.json
{
  "title": "Q3",
  "count": 12,
  "ok": true
}
```

03

## 중첩 표 분석 (VQA)

마스킹해 둔 복잡한 표를 따로 두 번째 모델에게 물어 구조를 복원한다.

- sub-slide 의 표 영역을 잘라 ASCII 표로 직렬화 후 LLM 입력
- 모델이 Key Row (헤더 1~3 행) + Key Column (좌측 ID 열) 인덱스 식별
- 식별된 키로 `TableTree` 행·열 트리 재구성
- parent-child 중복 → empty key → majority compression (depth 20, t=0.5) 정제


| H1 | H2 | H3 | H4 |
|----|----|----|----|
| K1 | -  | -  | -  |
| K2 | -  | -  | -  |
| K3 | -  | -  | -  |

04

## 병합 · 후처리

본문 JSON 의 표 자리에 복원된 표 JSON 을 다시 끼워 넣고 정리한다.

- 본문 JSON 의 "표 자리 N" 패턴을 normalize 후 정확 매칭
- 매칭된 위치에 nested table JSON 을 재귀 삽입 (`merge_tables_recursive`)
- key normalize → 부모-자식 중복 제거 → 빈 노드 prune 으로 트리 정제
- 최종 결과를 `merged_json_post/{file_id}.json` 으로 직렬화



05

## JSON · Excel 내보내기

결과를 웹에서 바로 보고, 표 형태로 받아 갈 수 있게 노출한다.

- FastAPI `/api/convert` 응답에 통합 JSON + Excel preview (≤200 행)
- `flatten_json` 으로 중첩 dict → (key1..key11, value) 행 평탄화
- `pandas` + `openpyxl` 로 시트 작성, alternating row shading
- `/api/excel/{file_id}` 가 원본 `.xlsx` 를 attachment 로 다운로드

